Spark入门实战系列--7.Spark Streaming（下）--实时流计算Spark Streaming实战

【注】该系列文章以及使用到安装包/测试数据 可以在《倾情大奉送--Spark入门实战系列》获取

1、实例演示

1.1 流数据模拟器

1.1.1 流数据说明

在实例演示中模拟实际情况，需要源源不断地接入流数据，为了在演示过程中更接近真实环境，将定义流数据模拟器。该模拟器主要功能：通过Socket方式监听指定的端口号，当外部程序通过该端口连接并请求数据时，模拟器将定时将指定的文件数据随机获取发送给外部程序。

1.1.2 模拟器代码

```
import java.io.{PrintWriter}
import java.net.ServerSocket
import scala.io.Source

object StreamingSimulation {
 // 定义随机获取整数的方法
 def index(length: Int) = {
   import java.util.Random
   val rdm = new Random
   rdm.nextInt(length)
 }

 def main(args: Array[String]) {
  // 调用该模拟器需要三个参数，分为为文件路径、端口号和间隔时间（单位：毫秒）
  if (args.length != 3) {
    System.err.println("Usage: <filename> <port> <millisecond>")
    System.exit(1)
  }

  // 获取指定文件总的行数
  val filename = args(0)
  val lines = Source.fromFile(filename).getLines.toList
  val filerow = lines.length

  // 指定监听某端口，当外部程序请求时建立连接
  val listener = new ServerSocket(args(1).toInt)
  while (true) {
    val socket = listener.accept()
    new Thread() {
      override def run = {
        println("Got client connected from: " + socket.getInetAddress)
        val out = new PrintWriter(socket.getOutputStream(), true)
        while (true) {
          Thread.sleep(args(2).toLong)
          // 当该端口接受请求时，随机获取某行数据发送给对方
          val content = lines(index(filerow))
          println(content)
          out.write(content + '\n')
          out.flush()
        }
        socket.close()
      }
    }.start()
  }
```

个人简介

郭景瞻，博客以家乡石山园为名，大数据图书作者，著《图解Spark：核心技术与案例实战》。

Spark核心技术与案例[《图解Spark：核心技术与案例实战》]

昵称：shishanyuan
园龄：8年7个月
荣誉：推荐博客
粉丝：741
关注：16
+加关注

< 2018年8月 >

日	一	二	三	四	五	六
29	30	31	1	2	3	4
5	6	7	8	9	10	11
12	13	14	15	16	17	18
19	20	21	22	23	24	25
26	27	28	29	30	31	1
2	3	4	5	6	7	8

搜索

找找看

随笔分类(107)

10.《图解Spark:核心技术与案例实战》(10)
20.Spark入门实战系列(19)
27.Spark精彩文章(6)
28.Databricks博客翻译(7)
30.Hadoop入门进阶课程(13)
40.持续集成(8)
50.图解Oracle10g备份恢复系列(20)
51.基于OracleLogminer数据同步(4)
58.数据库优化(1)
90.Hadoop数据分析平台(12)
91.杂项(7)

```
    }
}
```

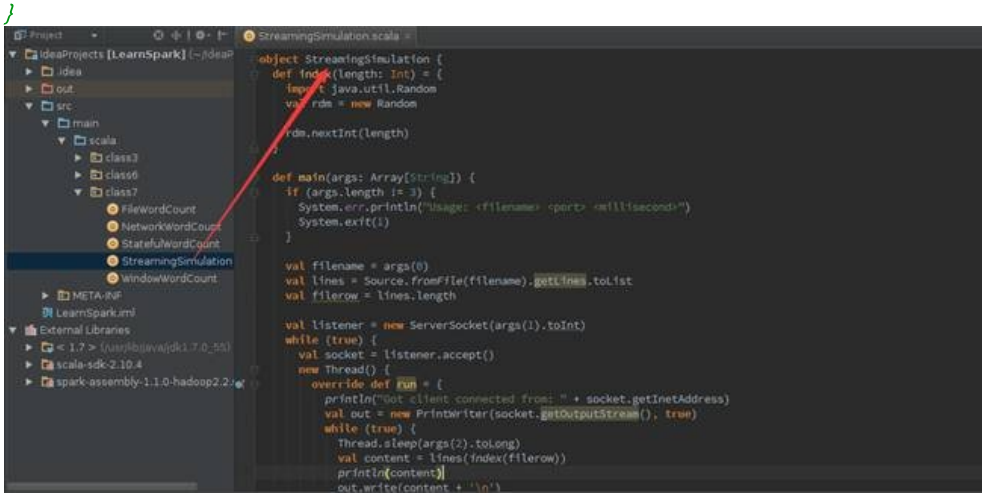

1.1.3 生成打包文件

【注】可以参见第3课《Spark编程模型（下）--IDEA搭建及实战》进行打包

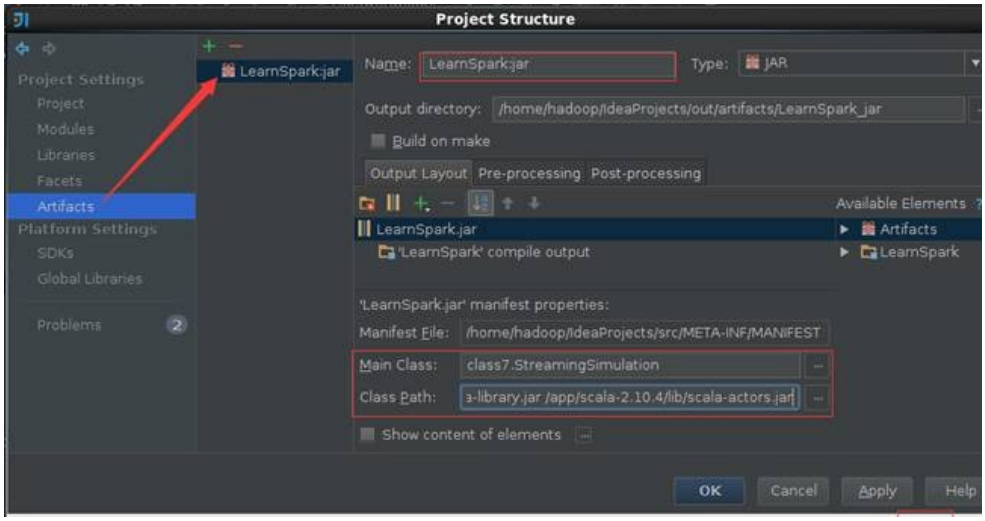

在打包配置界面中，需要在Class Path加入：/app/scala-2.10.4/lib/scala-swing.jar /app/scala-2.10.4/lib/scala-library.jar /app/scala-2.10.4/lib/scala-actors.jar ，各个jar包之间用空格分开，

点击菜单Build->Build Artifacts，弹出选择动作，选择Build或者Rebuild动作，使用如下命令复制打包文件到Spark根目录下

```
cd /home/hadoop/IdeaProjects/out/artifacts/LearnSpark_jar
cp LearnSpark.jar /app/hadoop/spark-1.1.0/
ll /app/hadoop/spark-1.1.0/
```

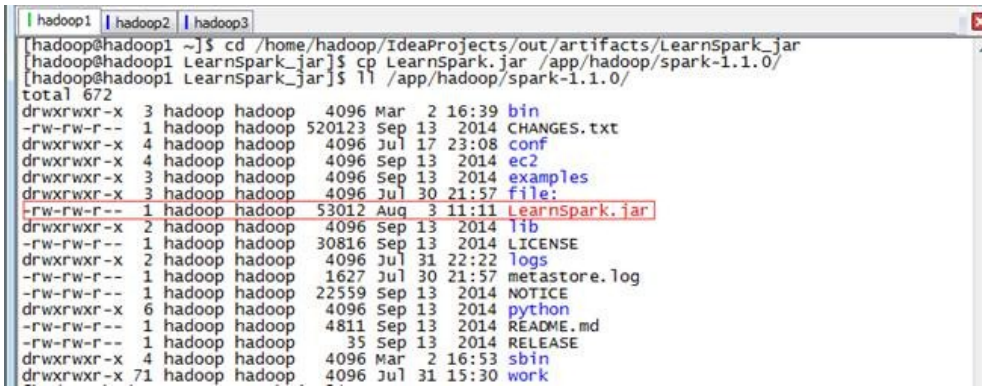

1.2 实例1：读取文件演示

1.2.1 演示说明

在该实例中Spark Streaming将监控某目录中的文件，获取在间隔时间段内变化的数据，然后通过Spark Streaming计算出改时间段内单词统计数。

1.2.2 演示代码

```
import org.apache.spark.SparkConf
import org.apache.spark.streaming.{Seconds, StreamingContext}
```

```
import org.apache.spark.streaming.StreamingContext._

object FileWordCount {
  def main(args: Array[String]) {
    val sparkConf = new SparkConf().setAppName("FileWordCount").setMaster("local[2]")

    // 创建Streaming的上下文，包括Spark的配置和时间间隔，这里时间为间隔20秒
    val ssc = new StreamingContext(sparkConf, Seconds(20))

    // 指定监控的目录，在这里为/home/hadoop/temp/
    val lines = ssc.textFileStream("/home/hadoop/temp/")

    // 对指定文件夹变化的数据进行单词统计并且打印
    val words = lines.flatMap(_.split(" "))
    val wordCounts = words.map(x => (x, 1)).reduceByKey(_ + _)
    wordCounts.print()

      // 启动Streaming
    ssc.start()
    ssc.awaitTermination()
  }
}
```

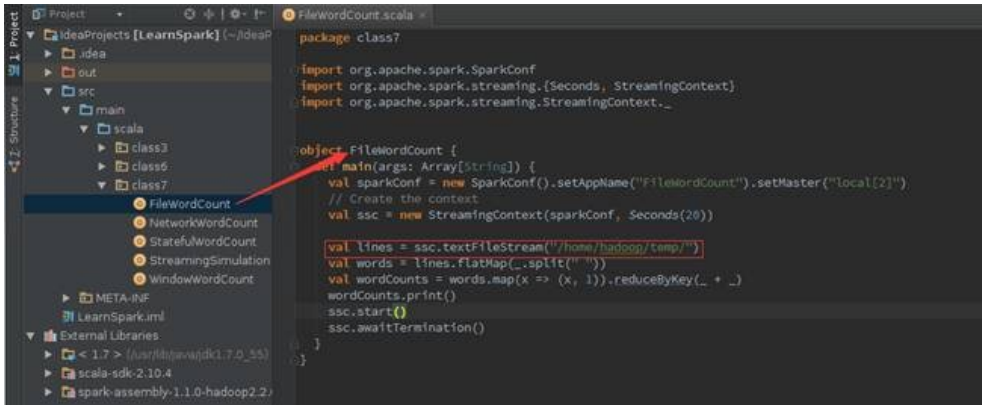

1.2.3 运行代码

第一步　创建Streaming监控目录

创建/home/hadoop/temp为Spark Streaming监控的目录，通过在该目录中定时添加文件内容，然后由Spark Streaming统计出单词个数

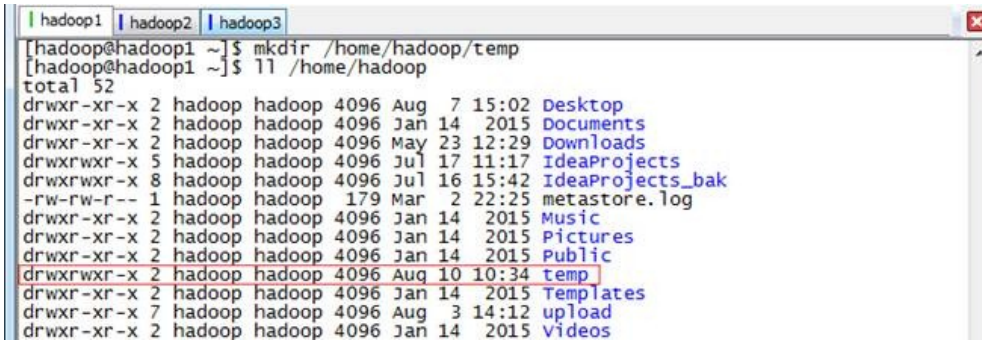

第二步　使用如下命令启动Spark集群

$cd /app/hadoop/spark-1.1.0

$sbin/start-all.sh

第三步　在IDEA中运行Streaming程序

在IDEA中运行该实例，由于该实例没有输入参数故不需要配置参数，在运行日志中将定时打印时间戳。如果在监控目录中加入文件内容，将输出时间戳的同时将输出单词统计个数。

clip_image012

1.2.4 添加文本及内容

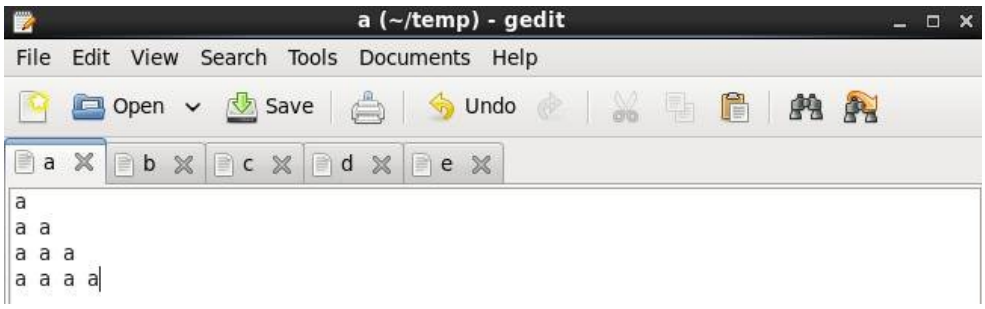

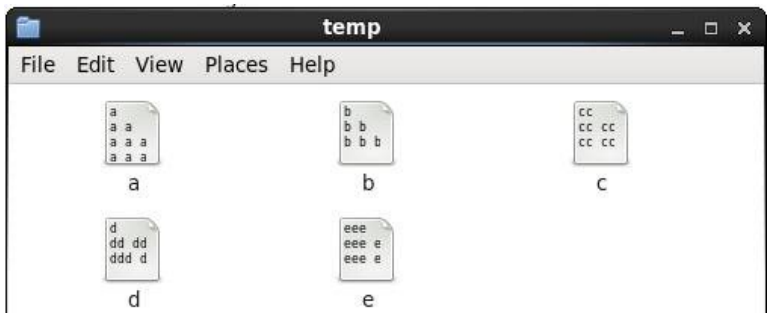

1.2.5 查看结果

第一步　查看IDEA中运行情况

在IDEA的运行日志窗口中，可以观察到输出时间戳的同时将输出单词统计个数

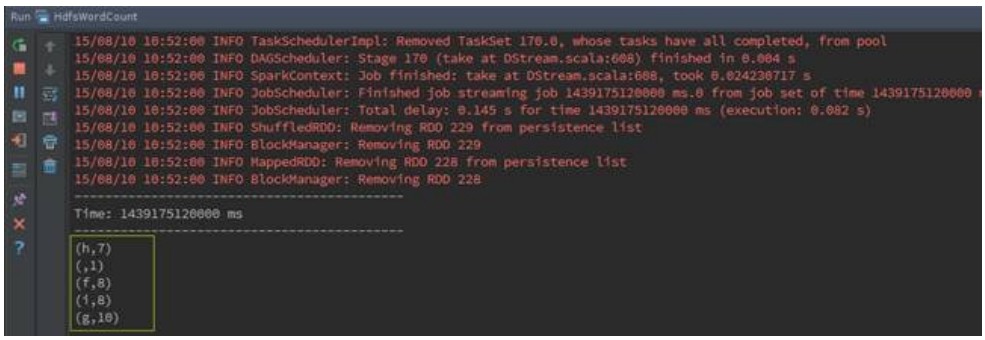

第二步　通过webUI监控运行情况

在http://hadoop1:4040监控Spark Streaming运行情况，可以观察到每20秒运行一次作业

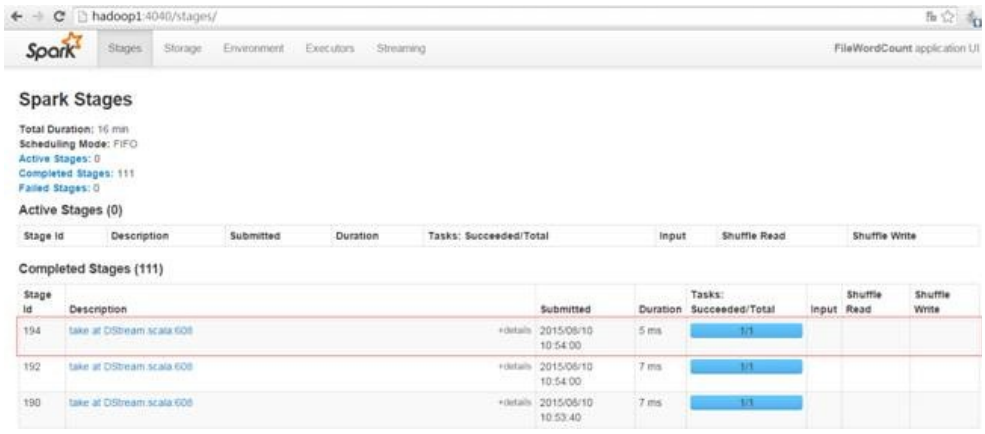

并且与其他运行作业相比在监控菜单增加了"Streaming"项目，点击可以看到监控内容：

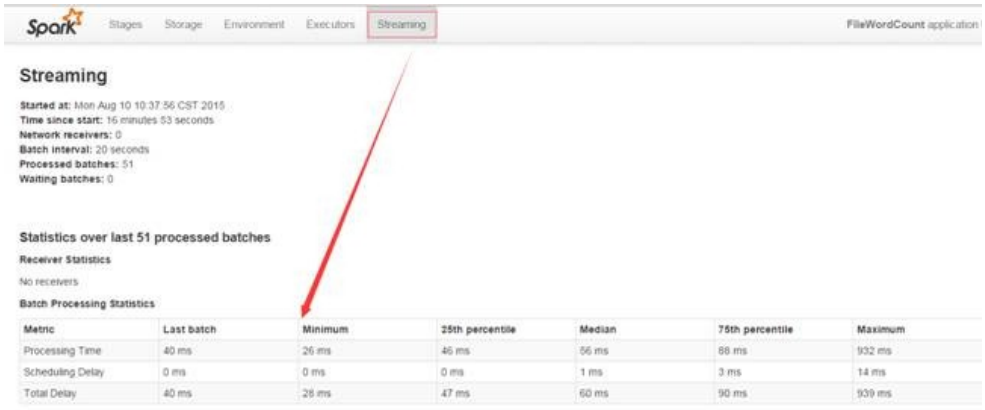

1.3 实例2：网络数据演示

1.3.1 演示说明

在该实例中将由4.1流数据模拟以1秒的频度发送模拟数据，Spark Streaming通过Socket接收流数据并每20秒运行一次用来处理接收到数据，处理完毕后打印该时间段内数据出现的频度，即各处理段时间之间状态并无关系。

1.3.2 演示代码

```
import org.apache.spark.{SparkContext, SparkConf}
import org.apache.spark.streaming.{Milliseconds, Seconds, StreamingContext}
import org.apache.spark.streaming.StreamingContext._
import org.apache.spark.storage.StorageLevel

object NetworkWordCount {
  def main(args: Array[String]) {
    val conf = new SparkConf().setAppName("NetworkWordCount").setMaster("local[2]")
    val sc = new SparkContext(conf)
    val ssc = new StreamingContext(sc, Seconds(20))

    // 通过Socket获取数据，该处需要提供Socket的主机名和端口号，数据保存在内存和硬盘中
    val lines = ssc.socketTextStream(args(0), args(1).toInt, StorageLevel.MEMORY_AND_DISK

    // 对读入的数据进行分割、计数
    val words = lines.flatMap(_.split(" "))
    val wordCounts = words.map(x => (x, 1)).reduceByKey(_ + _)

    wordCounts.print()
    ssc.start()
    ssc.awaitTermination()
  }
}
```

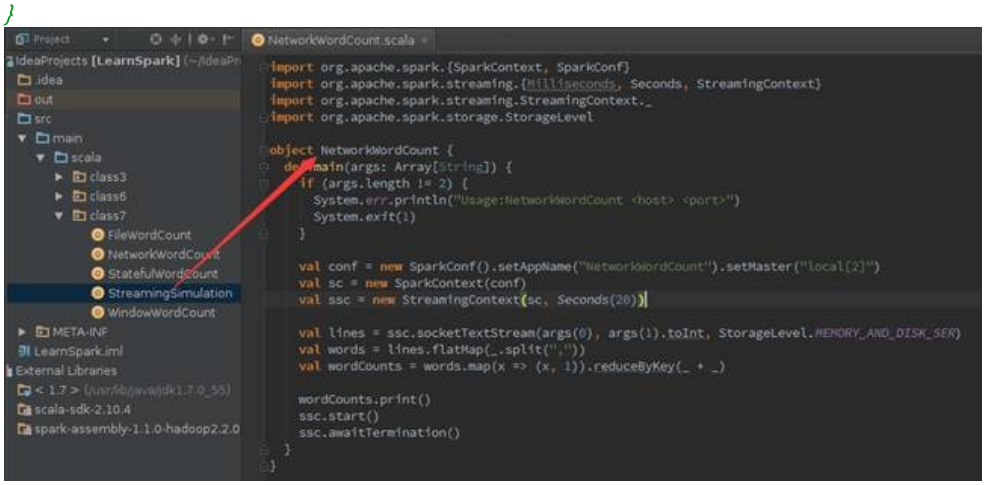

1.3.3 运行代码

第一步　启动流数据模拟器

启动4.1打包好的流数据模拟器，在该实例中将定时发送/home/hadoop/upload/class7目录下的people.txt数据文件（该文件可以在本系列配套资源目录/data/class7中找到），其中people.txt数据内容如下：

```
Michael
Andy
Justin

```

模拟器Socket端口号为9999，频度为1秒，

```
$cd /app/hadoop/spark-1.1.0
$java -cp LearnSpark.jar class7.StreamingSimulation /home/hadoop/upload/class7/people
1000
```

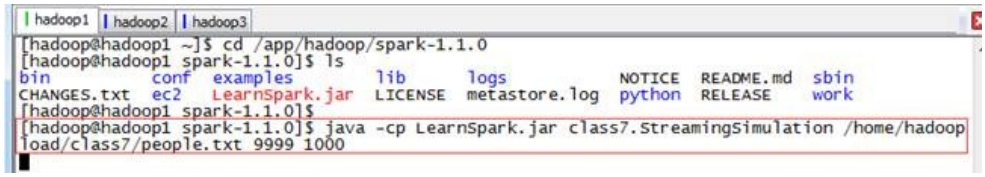

在没有程序连接时，该程序处于阻塞状态

第二步　在IDEA中运行Streaming程序

在IDEA中运行该实例，该实例需要配置连接Socket主机名和端口号，在这里配置参数机器名为hadoop1和端口号为9999

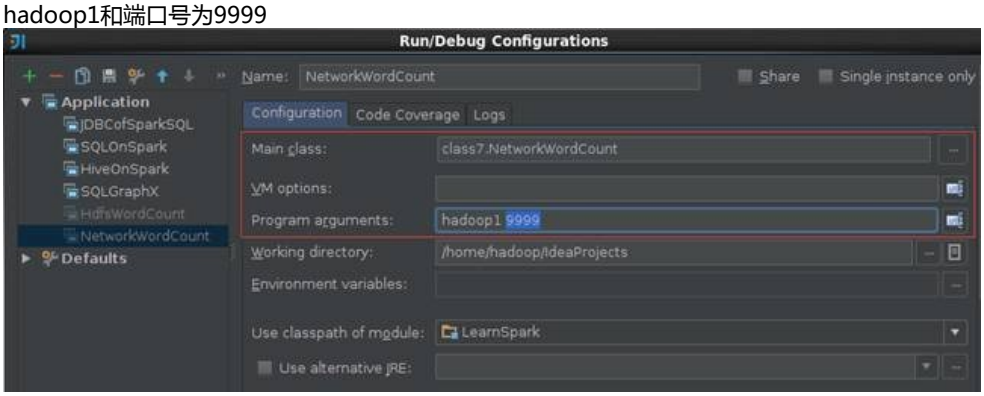

1.3.4 查看结果

第一步　观察模拟器发送情况

IDEA中的Spark Streaming程序运行与模拟器建立连接，当模拟器检测到外部连接时开始发送测试数据，数据是随机的在指定的文件中获取一行数据并发送，时间间隔为1秒

第二步　在监控页面观察执行情况

在webUI上监控作业运行情况，可以观察到每20秒运行一次作业

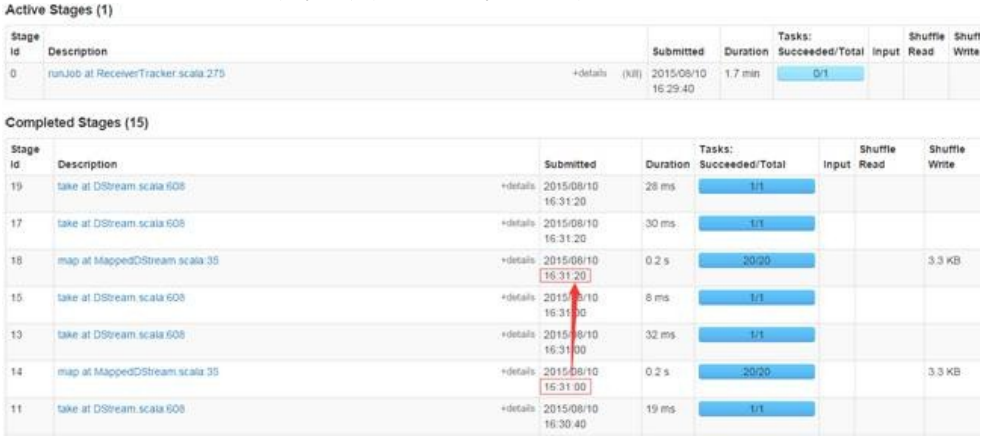

第三步　IDEA运行情况

在IDEA的运行窗口中，可以观测到的统计结果，通过分析在Spark Streaming每段时间内单词数为20，正好是20秒内每秒发送总数。

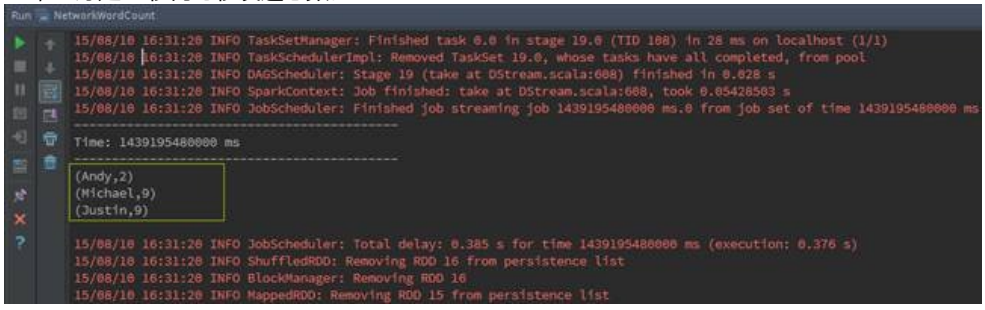

1.4 实例3：销售数据统计演示

1.4.1 演示说明

在该实例中将由4.1流数据模拟器以1秒的频度发送模拟数据（销售数据），Spark Streaming通过Socket接收流数据并每5秒运行一次用来处理接收到数据，处理完毕后打印该时间段内销售数据总和，需要注意的是各处理段时间之间状态并无关系。

1.4.2 演示代码

```
import org.apache.log4j.{Level, Logger}
```

```
import org.apache.spark.{SparkContext, SparkConf}
import org.apache.spark.streaming.{Milliseconds, Seconds, StreamingContext}
import org.apache.spark.streaming.StreamingContext._
import org.apache.spark.storage.StorageLevel

object SaleAmount {
  def main(args: Array[String]) {
    if (args.length != 2) {
      System.err.println("Usage: SaleAmount <hostname> <port> ")
      System.exit(1)
    }
    Logger.getLogger("org.apache.spark").setLevel(Level.ERROR)
    Logger.getLogger("org.eclipse.jetty.server").setLevel(Level.OFF)

    val conf = new SparkConf().setAppName("SaleAmount").setMaster("local[2]")
    val sc = new SparkContext(conf)
    val ssc = new StreamingContext(sc, Seconds(5))

   // 通过Socket获取数据，该处需要提供Socket的主机名和端口号，数据保存在内存和硬盘中
    val lines = ssc.socketTextStream(args(0), args(1).toInt,
      StorageLevel.MEMORY_AND_DISK_SER)
    val words = lines.map(_.split(",")).filter(_.length == 6)
    val wordCounts = words.map(x=>(1, x(5).toDouble)).reduceByKey(_ + _)

    wordCounts.print()
    ssc.start()
    ssc.awaitTermination()
  }
}
```

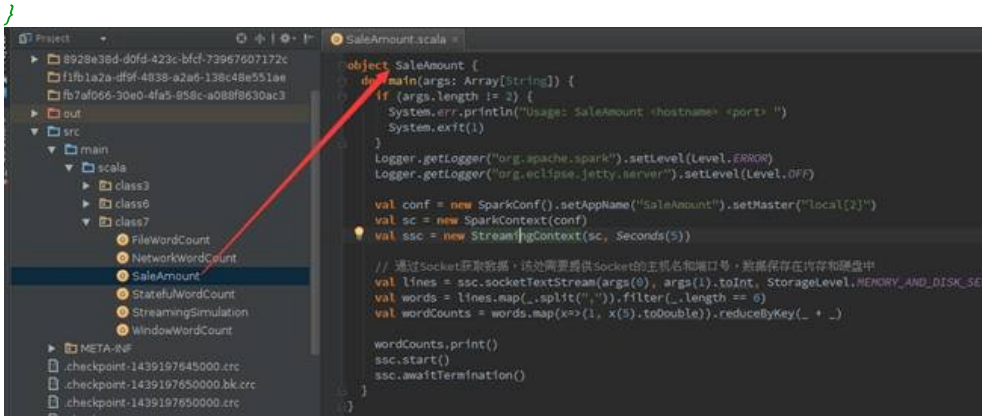

1.4.3 运行代码

第一步　启动流数据模拟器

启动4.1打包好的流数据模拟器，在该实例中将定时发送第五课/home/hadoop/upload/class5/saledata目录下的tbStockDetail.txt数据文件（参见第五课《5.Hive（下）--Hive实战》中2.1.2数据描述，该文件可以在本系列配套资源目录/data/class5/saledata中找到），其中表tbStockDetail字段分别为订单号、行号、货品、数量、金额，数据内容如下：

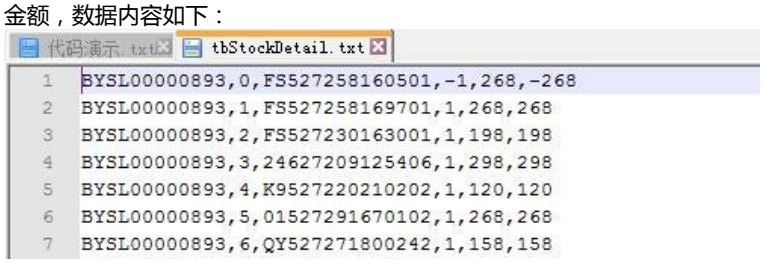

```
1  BYSL00000893,0,FS527258160501,-1,268,-268
2  BYSL00000893,1,FS527258169701,1,268,268
3  BYSL00000893,2,FS527230163001,1,198,198
4  BYSL00000893,3,24627209125406,1,298,298
5  BYSL00000893,4,K9527220210202,1,120,120
6  BYSL00000893,5,01527291670102,1,268,268
7  BYSL00000893,6,QY527271800242,1,158,158
```

模拟器Socket端口号为9999，频度为1秒

```
$cd /app/hadoop/spark-1.1.0
$java -cp LearnSpark.jar class7.StreamingSimulation
/home/hadoop/upload/class5/saledata/tbStockDetail.txt 9999 1000
```

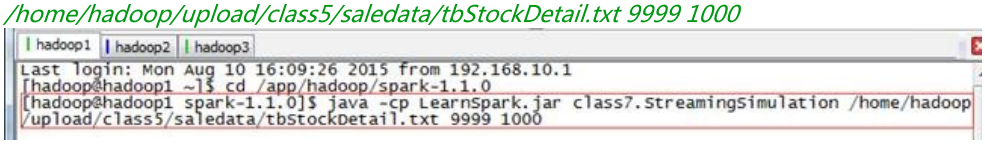

```
Last login: Mon Aug 10 16:09:26 2015 from 192.168.10.1
[hadoop@hadoop1 ~]$ cd /app/hadoop/spark-1.1.0
[hadoop@hadoop1 spark-1.1.0]$ java -cp LearnSpark.jar class7.StreamingSimulation /home/hadoop
/upload/class5/saledata/tbStockDetail.txt 9999 1000
```

在IDEA中运行该实例，该实例需要配置连接Socket主机名和端口号，在这里配置参数机器名为hadoop1和端口号为9999

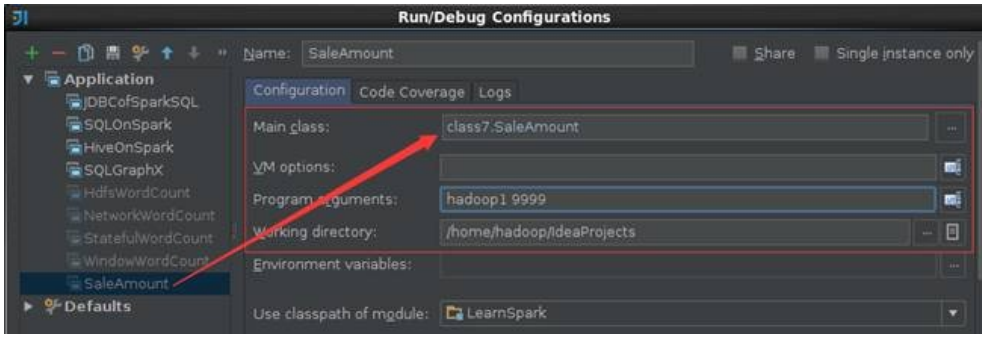

1.4.4 查看结果

第一步　观察模拟器发送情况
IDEA中的Spark Streaming程序运行与模拟器建立连接，当模拟器检测到外部连接时开始发送销售数据，时间间隔为1秒

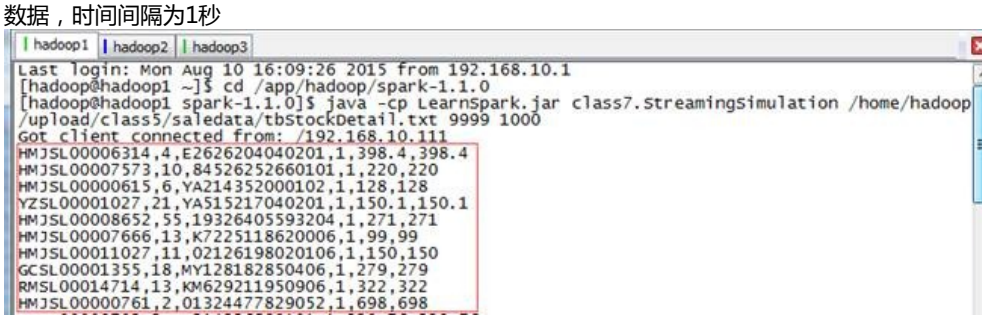

第二步　IDEA运行情况
在IDEA的运行窗口中，可以观察到每5秒运行一次作业（两次运行间隔为5000毫秒），运行完毕后打印该时间段内销售数据总和。

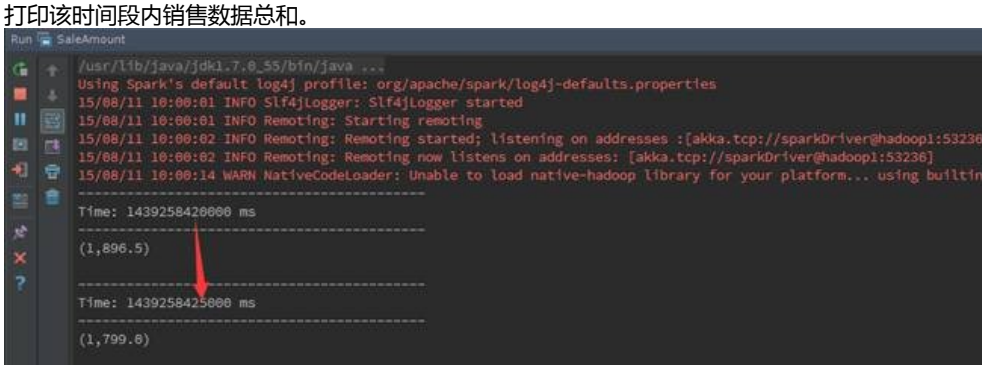

第三步　在监控页面观察执行情况
在webUI上监控作业运行情况，可以观察到每5秒运行一次作业

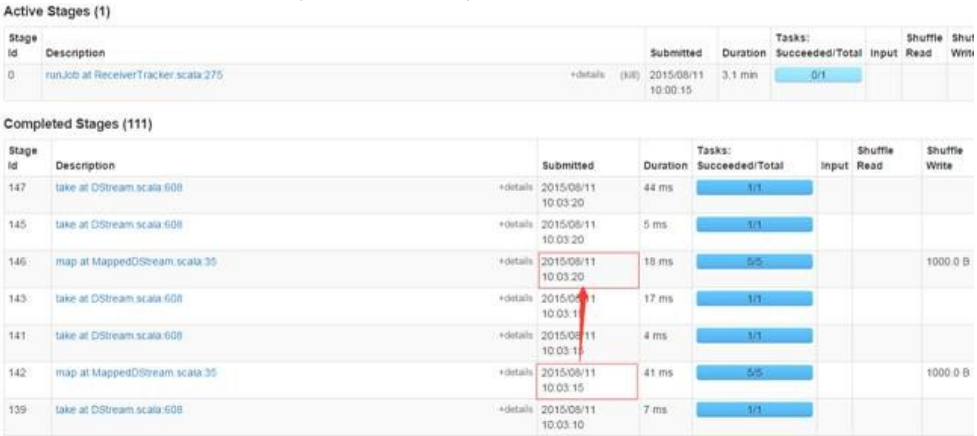

1.5 实例4：Stateful演示

1.5.1 演示说明

该实例为Spark Streaming状态操作，模拟数据由4.1流数据模拟以1秒的频度发送，Spar Streaming通过Socket接收流数据并每5秒运行一次用来处理接收到数据，处理完毕后打印程序启动后单词出现的频度，相比较前面4.3实例在该实例中各时间段之间状态是相关的。

1.5.2 演示代码

```
import org.apache.log4j.{Level, Logger}
import org.apache.spark.{SparkContext, SparkConf}
import org.apache.spark.streaming.{Seconds, StreamingContext}
```

```
import org.apache.spark.streaming.StreamingContext._

object StatefulWordCount {
  def main(args: Array[String]) {
    if (args.length != 2) {
      System.err.println("Usage: StatefulWordCount <filename> <port> ")
      System.exit(1)
    }
    Logger.getLogger("org.apache.spark").setLevel(Level.ERROR)
    Logger.getLogger("org.eclipse.jetty.server").setLevel(Level.OFF)

    // 定义更新状态方法，参数values为当前批次单词频度，state为以往批次单词频度
    val updateFunc = (values: Seq[Int], state: Option[Int]) => {
      val currentCount = values.foldLeft(0)(_ + _)
      val previousCount = state.getOrElse(0)
      Some(currentCount + previousCount)
    }

    val conf = new SparkConf().setAppName("StatefulWordCount").setMaster("local[2]")
    val sc = new SparkContext(conf)

    // 创建StreamingContext，Spark Steaming运行时间间隔为5秒
    val ssc = new StreamingContext(sc, Seconds(5))
    // 定义checkpoint目录为当前目录
    ssc.checkpoint(".")

    // 获取从Socket发送过来数据
    val lines = ssc.socketTextStream(args(0), args(1).toInt)
    val words = lines.flatMap(_.split(","))
    val wordCounts = words.map(x => (x, 1))

    // 使用updateStateByKey来更新状态，统计从运行开始以来单词总的次数
    val stateDstream = wordCounts.updateStateByKey[Int](updateFunc)
    stateDstream.print()
    ssc.start()
    ssc.awaitTermination()
  }
}
```

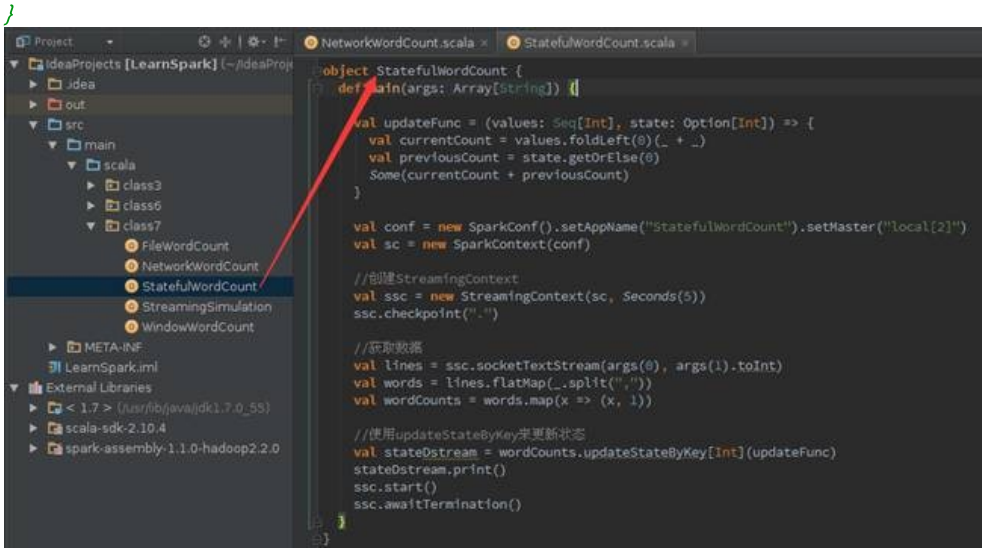

1.5.3 运行代码

第一步　启动流数据模拟器

启动4.1打包好的流数据模拟器，在该实例中将定时发送/home/hadoop/upload/class7目录下的people.txt数据文件（该文件可以在本系列配套资源目录/data/class7中找到），其中people.txt数据内容如下：

```
Michael
Andy
Justin

```

模拟器Socket端口号为9999，频度为1秒

```
$cd /app/hadoop/spark-1.1.0
$java -cp LearnSpark.jar class7.StreamingSimulation /home/hadoop/upload/class7/people
1000
```

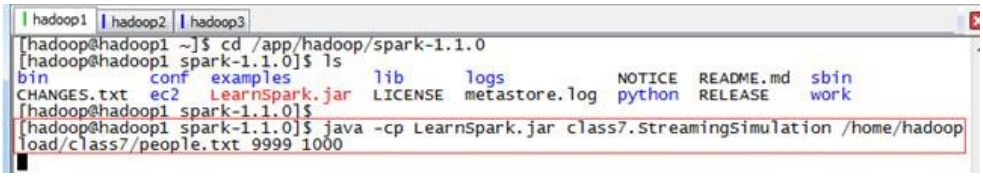

在没有程序连接时，该程序处于阻塞状态，在IDEA中运行Streaming程序
在IDEA中运行该实例，该实例需要配置连接Socket主机名和端口号，在这里配置参数机器名为hadoop1和端口号为9999

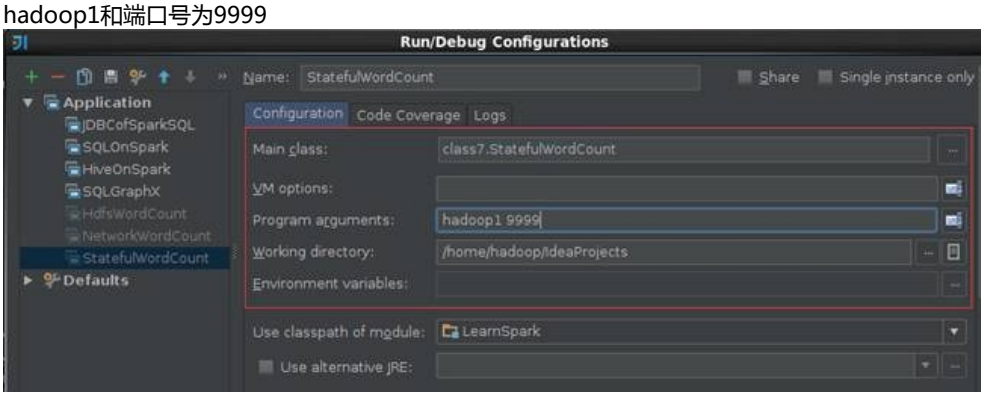

1.5.4 查看结果

第一步 IDEA运行情况
在IDEA的运行窗口中，可以观察到第一次运行统计单词总数为1，第二次为6，第N次为5(N-1)+1，即统计单词的总数为程序运行单词数总和。

第二步 在监控页面观察执行情况
在webUI上监控作业运行情况，可以观察到每5秒运行一次作业

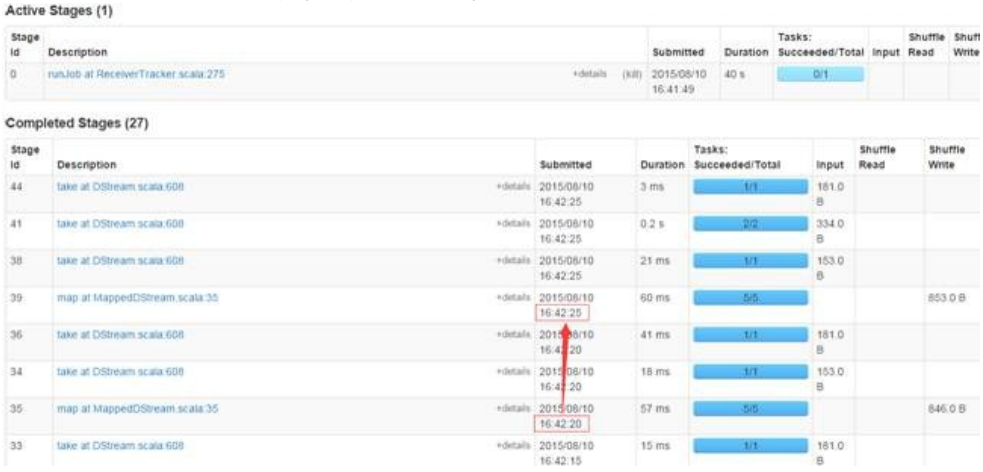

第三步 查看CheckPoint情况
在项目根目录下可以看到checkpoint文件

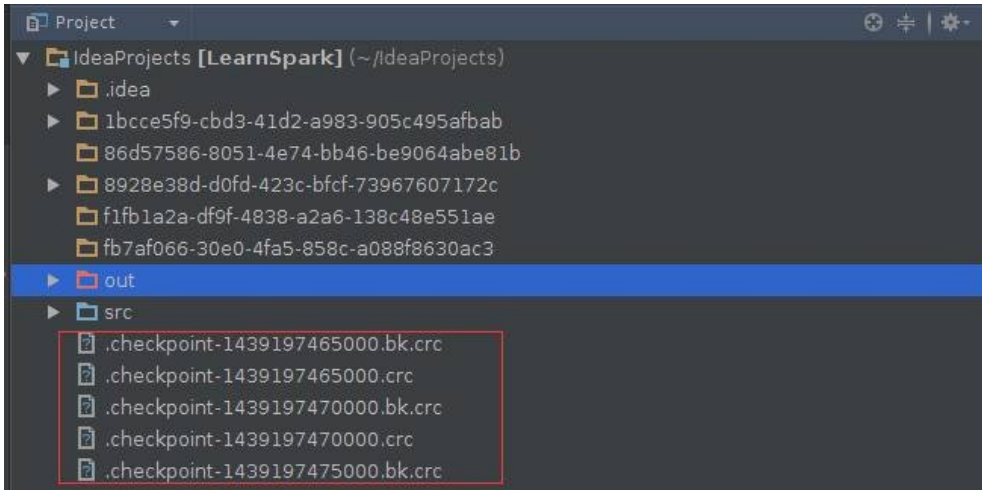

1.6 实例5：Window演示

1.6.1 演示说明

该实例为Spark Streaming窗口操作，模拟数据由4.1流数据模拟以1秒的频度发送，Spar Streaming通过Socket接收流数据并每10秒运行一次用来处理接收到数据，处理完毕后打印程序启动后单词出现的频度。相比前面的实例，Spark Streaming窗口统计是通过reduceByKeyAndWindow()方法实现的，在该方法中需要指定窗口时间长度和滑动时间间隔。

1.6.2 演示代码

```
import org.apache.log4j.{Level, Logger}
import org.apache.spark.{SparkContext, SparkConf}
import org.apache.spark.storage.StorageLevel
import org.apache.spark.streaming._
import org.apache.spark.streaming.StreamingContext._

object WindowWordCount {
  def main(args: Array[String]) {
    if (args.length != 4) {
      System.err.println("Usage: WindowWorldCount <filename> <port>
          <windowDuration> <slideDuration> ")
      System.exit(1)
    }
    Logger.getLogger("org.apache.spark").setLevel(Level.ERROR)
    Logger.getLogger("org.eclipse.jetty.server").setLevel(Level.OFF)

    val conf = new SparkConf().setAppName("WindowWordCount").setMaster("local[2]")
    val sc = new SparkContext(conf)

     // 创建StreamingContext
    val ssc = new StreamingContext(sc, Seconds(5))
     // 定义checkpoint目录为当前目录
    ssc.checkpoint(".")

    // 通过Socket获取数据，该处需要提供Socket的主机名和端口号，数据保存在内存和硬盘中
    val lines = ssc.socketTextStream(args(0), args(1).toInt, StorageLevel.MEMORY_ONLY_SE
    val words = lines.flatMap(_.split(" "))

    // windows操作，第一种方式为叠加处理，第二种方式为增量处理
    val wordCounts = words.map(x => (x , 1)).reduceByKeyAndWindow((a:Int,b:Int) => (a +
      b), Seconds(args(2).toInt), Seconds(args(3).toInt))
      //val wordCounts = words.map(x => (x , 1)).reduceByKeyAndWindow(_ +_, _ -
      _,Seconds(args(2).toInt), Seconds(args(3).toInt))

    wordCounts.print()
    ssc.start()
    ssc.awaitTermination()
  }
}
```

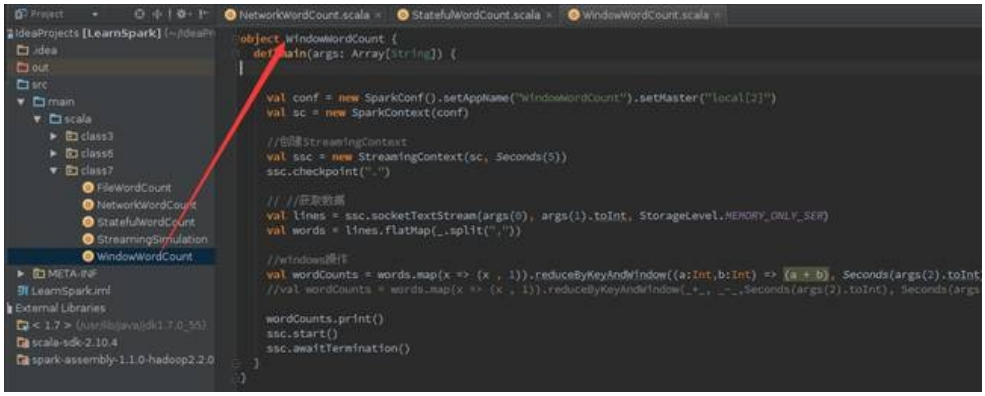

1.6.3 运行代码

第一步 启动流数据模拟器

启动4.1打包好的流数据模拟器，在该实例中将定时发送/home/hadoop/upload/class7目录下的people.txt数据文件（该文件可以在本系列配套资源目录/data/class7中找到），其中people.txt数据内容如下：

```
Michael
Andy
Justin

```

模拟器Socket端口号为9999，频度为1秒

$cd /app/hadoop/spark-1.1.0

$java -cp LearnSpark.jar class7.StreamingSimulation /home/hadoop/upload/class7/people.txt 9999 1000

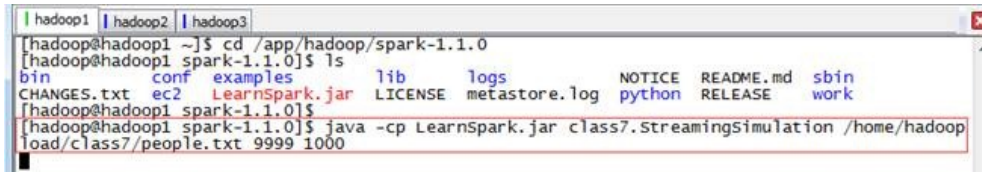

在没有程序连接时，该程序处于阻塞状态，在IDEA中运行Streaming程序

在IDEA中运行该实例，该实例需要配置连接Socket主机名和端口号，在这里配置参数机器名为hadoop1、端口号为9999、时间窗口为30秒和滑动时间间隔10秒

1.6.4 查看结果

第一步 IDEA运行情况

在IDEA的运行窗口中，可以观察到第一次运行统计单词总数为4，第二次为14，第N次为10(N-1)+4，即统计单词的总数为程序运行单词数总和。

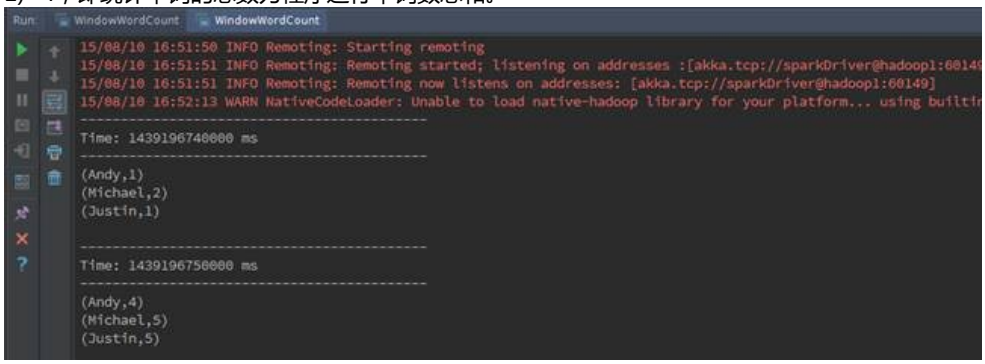

第二步 在监控页面观察执行情况

在webUI上监控作业运行情况，可以观察到每10秒运行一次作业

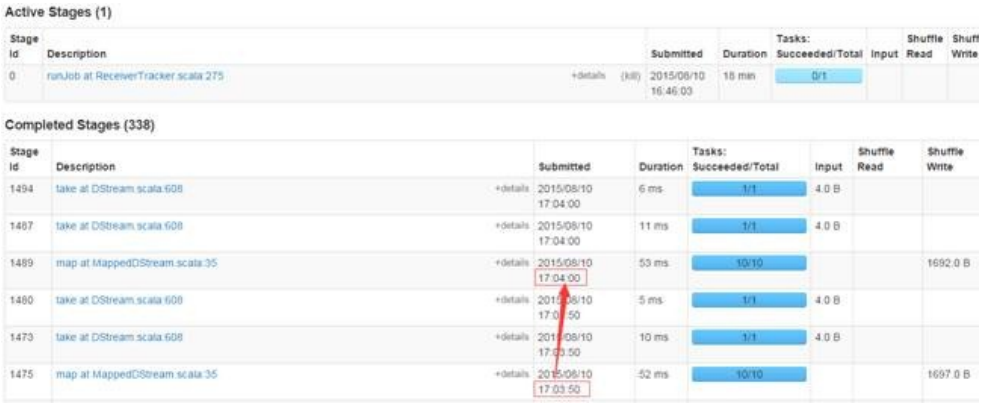

分类：20.Spark入门实战系列

« 上一篇：Spark入门实战系列--7.Spark Streaming（上）--实时流计算Spark Streaming原理介绍
» 下一篇：Spark入门实战系列--8.Spark MLlib（上）--机器学习及SparkMLlib简介

posted @ 2015-09-07 07:01 shishanyuan 阅读(21442) 评论(14) 编辑 收藏

发表评论

#1楼 2015-12-21 15:40 | zookeepers

老师，问一下，您的idea是装在linux系统里的吗？

支持(0) 反对(

#2楼[楼主] 2015-12-21 21:10 | shishanyuan

@ zookeepers
对，该系列中演示的idea是装在桌面的linux中
idea可以装在windows也可以装在linux系统中

支持(0) 反对(

#3楼 2015-12-22 15:35 | zookeepers

@ shishanyuan
老师，你好，我的idea是装在window中，在运行FileWordCount的程序时，总是找不到textFileStream路径，在window中可以直接引用spark集群中的路径吗？我在conf中已经设置好了Master,但是还是找不到

支持(0) 反对(

#4楼[楼主] 2015-12-24 10:36 | shishanyuan

@ zookeepers
我没有在windows系统中使用过，是不是textFileStream路径写法是不是需要处理一下，例如"file:\\\D:\...."这样形式？
在window中应该可以直接引用spark集群中的路径，现在cmd命令工具中ping一下spark master是否能够连通，如果使用机器名需要在hosts文件进行映射

支持(0) 反对(

#5楼 2016-07-26 15:10 | 开开好

老师你好，看了你的文章受益匪浅，不过中间也碰到了几个问题：
1,4.1中模拟器的 val content = lines(index(filerow))这一句，报错说是类型不匹配。我也有疑问，这个lines是Sng类型的list，要是取某个下标的元素是不是要加上indexof，我加上之后程序就没有报错了。这中间是什么原因？
2，第二个例子，我是在windows下跑的，但是无论是print还是保存到本地，都没有单词结果的统计。print只有时间信息，保存到本地的文件里面part-0000也是空的，什么都没有。刚接触spark streaming，有些问题理解的不是很彻，望老师能够给予解答。谢谢！！

支持(0) 反对(

#6楼[楼主] 2016-07-26 16:10 | shishanyuan

1、你理解lines是String类型的list这是没有问题，不过Scala中可以直接通过lines(index)来制定获取元素；
2、试一下wordCounts.collect().print()

支持(0) 反对(

#7楼 2016-08-26 17:23 | 小李飞菜刀

socket数据源的话，部署到yarn上，是一个节点接收据，还是其他节点也能接数据， 怎样一个处理过程？

支持(0) 反对(

#8楼 2017-01-06 12:00 | Z漫步

@ 开开好
“这些文件通过原子移动或重命名文件的方式在dataDirectory创建”
如果你是直接在目录下新建文件的话 是检测不到的，只能以上边的方式。我试过在其他目录新建文件然后复制进检测
录是可以打印出来的。 重命名的方式 我没有实验成功

支持(0) 反对(

#9楼 2017-01-12 15:19 | superlouxuwei

老师，你好，一直在学习你的文章，想请教您一下，我在使用textFileStream时，一直获取不到数据，请问您一下是
么原因呢？我的文件是放在linux主机的文件系统中，没有使用hdfs，请问和这个有原因吗？希望能得到您的回复，谢
谢您老师

支持(0) 反对(

#10楼 2017-03-29 11:28 | THHao

老师，您好，我用命令行提交.py文件，数据来自kinesis
lines = KinesisUtils.createStream(ssc, "testApp", "mySparkStream",
"https://kinesis.cn-north-1.amazonaws.com", "cn-north-1", InitialPositionInStream.LATEST, 2)
运行报错：
Spark Streaming's Kinesis libraries not found in class path. Try one of the following.

1. Include the Kinesis library and its dependencies with in the
spark-submit command as

$ bin/spark-submit --packages org.apache.spark:spark-streaming-kinesis-asl:2.1.0 ...

2. Download the JAR of the artifact from Maven Central http://search.maven.org/,
Group Id = org.apache.spark, Artifact Id = spark-streaming-kinesis-asl-assembly, Version = 2.1.0.
Then, include the jar in the spark-submit command as

$ bin/spark-submit --jars <spark-streaming-kinesis-asl-assembly.jar> ...

TypeError Traceback (most recent call last)
<ipython-input-12-aa6ce35534f6> in <module>()
9
10 lines = KinesisUtils.createStream(ssc, "testApp", "mySparkStream",
---> 11 "https://kinesis.cn-north-1.amazonaws.com", "cn-north-1", InitialPositionInStream.LATEST,

/usr/lib/spark/python/pyspark/streaming/kinesis.pyc in createStream(ssc, kinesisAppName, streamN
me, endpointUrl, regionName, initialPositionInStream, checkpointInterval, storageLevel, awsAccessKe
Id, awsSecretKey, decoder)
75 try:
76 # Use KinesisUtilsPythonHelper to access Scala's KinesisUtils
---> 77 helper = ssc._jvm.org.apache.spark.streaming.kinesis.KinesisUtilsPythonHelper()
78 except TypeError as e:
79 if str(e) == "'JavaPackage' object is not callable":

TypeError: 'JavaPackage' object is not callable

怎么解决啊？谢谢了

支持(0) 反对(

#11楼[楼主] 2017-03-31 09:33 | shishanyuan

@ THHao
问题主要出在“Spark Streaming's Kinesis libraries not found in class path. Try one of the following.”根据示需要引入Kinesis 相关jar包

支持(1) 反对(

#12楼 2017-03-31 15:14 | THHao

@ shishanyuan
谢谢您，我再试试

支持(0) 反对(

#13楼 2017-08-30 11:23 | loverlself

老师你好，最近在学习您的文章，在学习到本节到时候，运行实例2的代码，出现如下报错

```
Exception in thread "main" java.lang.NoClassDefFoundError: org/apache/spark/streaming/St
    at com.netbox.FileWordCount$.main(FileWordCount.scala:12)
    at com.netbox.FileWordCount.main(FileWordCount.scala)
Caused by: java.lang.ClassNotFoundException: org.apache.spark.streaming.StreamingContext
    at java.net.URLClassLoader.findClass(URLClassLoader.java:381)
    at java.lang.ClassLoader.loadClass(ClassLoader.java:424)
    at sun.misc.Launcher$AppClassLoader.loadClass(Launcher.java:331)
    at java.lang.ClassLoader.loadClass(ClassLoader.java:357)
    ... 2 more
```

我到环境是jdk1.8.0_111，scala2.10.5，hadoop2.6.1，spark1.6.2，idea是在centos上运行的，请问一下是什么原因？

支持(0) 反对(

#14楼 2018-03-06 22:59 | 小鸟爱吃醋

Spark Streaming实时流处理项目实战
网盘地址：https://pan.baidu.com/s/1nwuLT3N 密码：hrck

支持(0) 反对(

刷新评论 刷新页面 返回顶